


# Tentamen 2023-10-26, lösningsförslag

1/

```
1 import numpy as np
2 from scipy.integrate import solve_ivp
3 import matplotlib.pyplot as plt
4
5 def ODE_fun(t, y):
6     yprime = np.sin(y*t)
7     return yprime
8
9 y0 = [1]
10 tspan = [0, 5]
11 eval = np.arange(tspan[0], tspan[1], 0.01)
12 result = solve_ivp(ODE_fun, tspan, y0, t_eval = eval)
13
14 plt.plot(result.t, result.y[0])
15 plt.show()
```



2/  $m y''(t) + c y'(t) + k y(t) = 0 \Rightarrow y''(t) = (-c y'(t) - k y(t)) / m$   
skriv om på formen  $\bar{y}'(t) = \bar{f}(t; \bar{y})$

$$\begin{aligned} u_1 &= y \Rightarrow u_1' = y' \\ u_2 &= y' \Rightarrow u_2' = y'' \end{aligned} \Rightarrow \begin{cases} u_1' = u_2 \\ u_2' = (-c \cdot u_2 - k \cdot u_1) / m \\ u_1(0) = 0, u_2(0) = 1 \end{cases}$$

```
1 import numpy as np
2 from scipy.integrate import solve_ivp
3
4 def ODE_fun(t, u, m, k, c):
5     u1, u2 = u
6     u = [u2, (-c*u2 - k*u1)/m]
7     return u
8
9 u0 = np.array([0, 1]) # y(0) resp. y'(0)
10 tspan = [0, 2]
11 m = 2
12 k = 100
13 c = 0.1
14 eval = np.arange(tspan[0], tspan[1], 0.01)
15 result = solve_ivp(ODE_fun, tspan, u0, t_eval=eval, args=(m, k, c))
```

3/ a/ En stokastisk process som är "minnesfri" ("memoryless"): nästa steg kan bestämmas enbart utgående från befintligt steg.

b/ Exempel: stokastisk SIR-modell eller stokastisk Pred - Prey

c/ Exempel: Brownsk rörelse

d/ Exempel: "Hur långt i medeltal har en partikel rört sig efter  $t$  sekunder?"

---

4/ a/ Noggrannhetsordning är lutningen på linjen där diskretiseringsfelet dominerar (dvs för  $h > 10^{-3}$ )

b/ maskinepsilon  $\varepsilon_m \approx 10^{-16}$  och är orsaken till att felet inte kan bli  $< 10^{-16}$  (i bilden  $\approx 10^{-15}$ )

c/ man kan se att om felet minskar från t.ex.  $10^{-1}$  till  $10^{-2}$  så förbättras felet från  $10^{-6}$  till  $10^{-16} \Rightarrow$

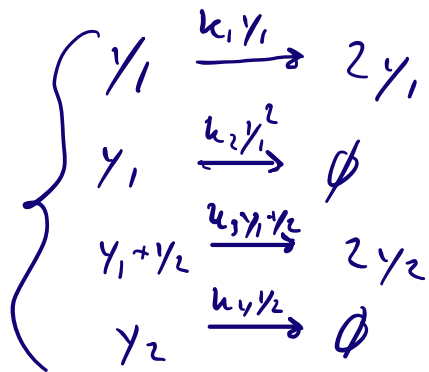
minskning feletor 10 ger minskning av felet med faktor  $10^4 \Rightarrow$  u.o. 4 dvs klassisk Runge-kutta.

---

5/  $N = \dots$ , t.ex  $N = 1000$   
 $\text{cost}_a = 3$   
 for  $i = 1, 2, \dots, N$   
 $\text{cost}_m \equiv \text{normal}(\mu_r, \sigma_r)$  % normalford.  
 $\text{cost}_e = \text{ek\_pris}()$   
 $\text{tot\_cost}[i] = \text{cost}_m + \text{cost}_e$   
 end\_for  
 $\text{mean\_cost} = \text{mean}(\text{tot\_cost} + \text{cost}_a)$

6/ ODE: 
$$\begin{cases} y_1' = k_1 y_1 - k_2 y_1^2 - k_3 y_1 \cdot y_2 \\ y_2' = k_3 y_1 \cdot y_2 - k_4 y_2 \end{cases}$$

a/ stokastisk modell:




b/ stochiometrimatris: 
$$\begin{pmatrix} 1 & 0 \\ -1 & 0 \\ -1 & 1 \\ 0 & -1 \end{pmatrix}$$

propensiteter: 
$$p = \begin{pmatrix} k_1 \cdot y_1 \\ k_2 \cdot y_1^2 \\ k_3 \cdot y_1 \cdot y_2 \\ k_4 \cdot y_2 \end{pmatrix}$$

7/ Stabilitetsområden visar för vilka  
 val av steglängd  $h$  som metoden är  
 numeriskt stabil (eller instabil).  
 Området härleds genom att applicera  
 en viss metod på testekvationen  
 $y'(t) = \lambda \cdot y(t)$ ,  $\text{Re}(\lambda) < 0$ .

Om numerisk lösning växande för  
 ett visst  $h$ , så är metoden instabil  
 för de  $h$ -värdena. Man får då ett  
 område i  $\lambda h$ -planet.

Ovillkorligt stabil innebär att  
 lösningen är avtagande för alla  $h$   
 (givet  $\text{Re}(\lambda) < 0$ ), dvs i hela vänstra  
 halvplanet, d.v.s



8/ Exakt lösning:

$$y(t_{i+1}) = y(t_i) + h y'(t_i) + \frac{h^2}{2} y''(t_i) + \frac{h^3}{6} y'''(t_i) + O(h^4)$$

Numerisk lösning:

$$\begin{aligned} y_{i+1} &= y_i + h \cdot a f(t_i, y_i) + h b \cdot f(t_{i+1}, y_{i+1}) = y_i + h \cdot a y'_i + h b y'_{i+1} \\ &= y_i + h a y'_i + h b \left( y'_i + h y''_i + \frac{h^2}{2} y'''_i + O(h^4) \right) = \end{aligned}$$

$$= y_i + h y_i' (a+b) + h^2 b y_i'' + \frac{h^3}{2} \cdot b \cdot y_i''' + O(h^4)$$

$$y_i = y(t_i) \quad (\text{lokal + fel}):$$

$$y(t_{i+1}) - y_{i+1} = y_i + h y_i' + \frac{h^2}{2} y_i'' + \frac{h^3}{6} y_i''' + O(h^4) -$$

$$- y_i - h y_i' (a+b) - h^2 b y_i'' - \frac{h^3}{2} \cdot b \cdot y_i''' + O(h^4) =$$

$$= h y_i' (a+b-1) + h^2 y_i'' \left( \frac{1}{2} - b \right) + h^3 y_i''' \left( \frac{1}{6} - \frac{b}{2} \right) + O(h^4)$$

$\underbrace{a+b-1}_{=0 \text{ da } a=\frac{1}{2}, b=\frac{1}{2}} \quad \underbrace{\left( \frac{1}{2} - b \right)}_{=0 \text{ da } b=\frac{1}{2}}$

$a=b=\frac{1}{2}$  ger högst 9 möjliga n.o. :

$$y(t_{i+1}) - y_{i+1} = h^3 y_i''' \left( \frac{1}{6} - \frac{1/2}{2} \right) + O(h^4) = -\frac{1}{12} h^3 y_i''' + O(h^4)$$

9/

Ange vilken typ av metod (kolumn) är lämplig i vilken tillämpning (rad)

	Stokastisk metod	Deterministisk metod
Kemisk reaktion med få molekyler	<input checked="" type="radio"/>	<input type="radio"/>
Lösa en väderprognosmodell	<input type="radio"/>	<input checked="" type="radio"/>
Matematisk ODE	<input type="radio"/>	<input checked="" type="radio"/>
Optionsprissättning	<input checked="" type="radio"/>	<input type="radio"/>
Integral 2D	<input type="radio"/>	<input checked="" type="radio"/>
Kemisk reaktion med många molekyler	<input type="radio"/>	<input checked="" type="radio"/>
Integral 20D	<input checked="" type="radio"/>	<input type="radio"/>
Simulera trafikflöden i en stad	<input checked="" type="radio"/>	<input type="radio"/>

10 / ODE'n är en styv ODE och explicita metoder får (sannolikt) stabilitetsproblem pga små stabilitetsområden. man bör därför välja en implicit metod, som har större stabilitetsområden.

Om man väljer en explicit metod kommer steglängden pressas ned pga instabilitet. Detta leder till väldigt lång beräkningstid.

notera, detta gäller adaptiva metoder, men alla lösare i t.ex. Scipy är adaptiva.

---

11/ Testeku.  $y' = \lambda y$

$$\begin{cases} u_1 = \lambda y_i \\ u_2 = \lambda (y_i + f \cdot h \cdot u_1) = \lambda (y_i + f \cdot h \cdot \lambda y_i) \end{cases}$$

$$\begin{aligned} y_{i+1} &= y_i + h \cdot a_1 \cdot \lambda y_i + h a_2 \cdot \lambda (y_i + f \cdot h \cdot \lambda y_i) = \\ &= y_i + h a_1 \lambda y_i + h a_2 \lambda y_i + h^2 a_2 \lambda^2 f \cdot y_i = \left(1 + h \lambda \underbrace{(a_1 + a_2)}_{=1} + \underbrace{a_2 f \cdot (h \lambda)^2}_{=\frac{1}{2}}\right) \cdot y_i \\ &= \left(1 + h \lambda + \frac{1}{2} (h \lambda)^2\right) \cdot y_i \Rightarrow \end{aligned}$$

$$\Rightarrow y_k = \left(1 + h \lambda + \frac{1}{2} (h \lambda)^2\right)^k \cdot y_0 = \left(1 + z + \frac{1}{2} z^2\right)^k \cdot y_0$$

stabilitet då  $\left| \frac{1}{2} z^2 + z + 1 \right| < 1$

$\therefore$  samma stabilitets villkor oberoende av val av  $a_1, a_2, p$  och  $h f$ .

stabilitets villkoret är  $\left| \frac{1}{2} z^2 + z + 1 \right| < 1$

12/  $x_i = r_i \cdot \cos(\theta_i)$   
 $y_i = r_i \cdot \sin(\theta_i)$ ,  $i = 1, \dots, n$



$\theta_i \in \mathcal{U}(-\pi, \pi)$ ,  $r_i$  ges ur  $\text{radie}(R, n)$

$x = \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix}, y = \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix}$  ges ur  $x, y = \text{RandomPointsOnDisc}(R, n)$

9/ Algorithm:

- skapa  $\theta_i \in U(-\pi, \pi)$ . Ger ur  $U(0, 1)$  genom  
 $\theta = -\pi + 2 \cdot \pi \cdot u$  där  $u \in U(0, 1)$

I numpy:  $\theta = -\pi + 2 \cdot \pi \cdot \text{np.random.rand}(n, 1)$   
eller  
 $\theta = \text{np.random.uniform}(-\pi, \pi, n)$

- skapa  $r_i$ : Använd radii  $(R, n)$   
 $r = \text{radii}(R, n)$

- Beräkna vektorer  $x$  och  $y$ . Använd  
elementvis multiplikation ( $\text{np.multiply}$   
eller  $*$  i numpy).

$$x = r * \text{np.cos}(\theta)$$

$$y = r * \text{np.sin}(\theta)$$

eller

$$x = \text{np.multiply}(r, \text{np.cos}(\theta))$$

$$y = \text{np.multiply}(r, \text{np.sin}(\theta))$$

"scriptet" här blir:

$R = \dots$

$n = \dots$

$x, y = \text{RandomPointsOnDisc}(R, n)$   
 $\text{plot}(x, y)$  as dots

med matplotlib t.ex

$\text{plt.scatter}(x, y)$



b/ Hitta slumpvariabelns fördelning (PDF):

$$f(r) = \begin{cases} 0 & r < 0 \\ 2r/R^2 & 0 \leq r \leq R \\ 0 & r > R \end{cases}$$


Använd invers transform sampling för att gå från  $U(0,1)$  till annan fördelning.

Använd CDF:

$$\int_{-\infty}^{r_0} \frac{2r}{R^2} dr = \frac{2}{R^2} \int_0^{r_0} r dr = \frac{2}{R^2} \left[ \frac{r^2}{2} \right]_0^{r_0} = \frac{1}{R^2} (r_0^2 - 0)$$

$$\text{CDF: } F(r_0) = \frac{1}{R^2} \cdot r_0^2. \text{ Notera att } F(r_0)$$

går från 0 till 1 för alla  $r_0 \leq R$



vi kan nu välja  $u \in U(0,1)$   
och hitta motsvarande  
 $r_0 \in f(r)$

$$\Rightarrow u = \frac{r_0^2}{R^2} \Rightarrow r_0^2 = u \cdot R^2 \Rightarrow r_0 = \sqrt{u \cdot R^2} = R \cdot \sqrt{u}$$

I numpy:

```
def radie(R, n)
```

```
    u = np.random.rand(n, 1)
```

```
    r = R * np.sqrt(u)
```

```
    return r
```

Förslag på kod i numpy (men krävs inte färdig och fungerande kod på tentan)

```
import numpy as np
import matplotlib.pyplot as plt

def radie(R,n):
    u = np.random.rand(n,1)
    r = R*np.sqrt(u)
    return r

def randomPointsOnDisc(R,n):
    theta = -np.pi + 2*np.pi*np.random.rand(n,1)
    r = radie(R,n)
    x = np.multiply(r, np.cos(theta))
    y = np.multiply(r, np.sin(theta))
    return x, y

R = 5      # Radius
n = 10000 # Number of points
x, y = randomPointsOnDisc(R,n)
plt.scatter(x,y, s=1)
axisticks=np.arange(-R,R+1,step=1)
plt.xticks(axisticks)
plt.yticks(axisticks)
plt.grid()
plt.show()
```